STANFORD CS336 · LANGUAGE MODELING FROM SCRATCH

第 01 课复习资料

课程概览与分词

目录

1 先定位：这门课究竟在解决什么问题？ 2

2 接上主线：语言模型为什么先需要分词？ 3

3 理解取舍：为什么不直接用字符、字节或单词？ 4

4 核心例子：BPE 怎样从语料中学出词表？ 5

5 把训练结果用起来：编码与解码分别怎么做？ 6

6 从课堂玩具到实用分词器，还要补上什么？ 7

7 一页速查：把本课压回一条主线 8

8 自测：合上前文，检查自己是否真的理解 9

9 参考答案与资料来源 10

阅读主线：预算约束 → 文本表示 → 三种方案的取舍 → BPE 的训练、编码与解码。

1 先定位：这门课究竟在解决什么问题？

1.1 全课程的主线：给定资源，构建更好的语言模型

CS336 强调通过亲手构建来理解语言模型。一个设计选择通常会影响整条链路：分词改变序列长度，序列长度影响计算成本，成本又决定同一预算能做多少训练与实验。

本课的核心问题：怎样在有限的计算与数据预算下，把原始文本变成模型适合处理的序列？

学习目标可分成三层：**机制**是组件如何工作；**思维方式**是如何判断瓶颈、设计实验和考虑扩展；**经验直觉**是某个设置在实验中是否有效。前两者较容易迁移，第三者往往依赖模型规模与数据条件。

1.2 五个模块：每个模块回答一个问题

模块	需要回答的问题
基础 Basics	文本如何编码？模型如何预测？参数如何训练？
系统 Systems	如何减少数据搬运，利用 GPU，并组织多卡计算与推理？
扩展规律 Scaling	如何通过较小实验，选择更大规模的模型与训练配方？
数据 Data	如何选择、清洗、去重和混合数据，并评估效果？
对齐 Alignment	如何用示范、偏好或可验证反馈，进一步改善模型行为？

1.3 背景知道到什么程度就够了？

从统计语言模型到神经网络、Transformer，再到大规模预训练与后训练，外部使用形式不断变化，但表示、计算、优化和数据仍是底层问题。公开权重有助于使用模型；研究与复现完整训练还需要方法、代码和数据等信息。

第一课列举历史与开放模型，是为了说明课程的背景，不要求背模型排行榜。模型结构、并行训练和强化学习在这里属于**全课程预告**，本课需要深入掌握的是**分词与 BPE**。

复习路线：先读第 2–6 节建立理解；快速回顾用第 7 节；自测见第 8 节。

2 接上主线：语言模型为什么先需要分词？

本节目标：区分文本、token、ID、向量，以及模型预测的对象。

2.1 从文字到预测，再回到文字

人看到的是字符串。分词器先把它转换成整数序列，模型再通过嵌入表把这些整数转换成向量。整数在这里是**编号**，不是可以直接比较语义大小的数值。

$$\text{原始文本} \xrightarrow{\text{encode}} \text{token ID 序列} \xrightarrow{\text{嵌入查表}} \text{向量序列}$$

$$\text{向量序列} \xrightarrow{\text{模型}} \text{下一 token 的概率} \xrightarrow{\text{选择一个 ID}} \text{扩展序列} \xrightarrow{\text{decode}} \text{文本}$$

补充背景：对自回归语言模型，若 token 序列为 $x_1, \ldots, x_T$，则

$$p_\theta(x_1, \ldots, x_T) = \prod_{t=1}^{T} p_\theta(x_t \mid x_{<t}).$$

其中 θ 是模型参数，$x_{<t}$ 是前文 token；第一个 token 可在起始标记等约定条件下预测。训练时提高真实后续 token 的概率；生成时反复预测、选择并接回序列。本课无需展开 Transformer 内部结构。

2.2 分词器的两个接口

```
encode(text: str) -> list[int]
decode(ids: list[int]) -> str
```

对于本课不做有损归一化的字节级分词器，需要满足

$$\text{decode}(\text{encode}(s)) = s.$$

这是“原文能够还原”。反过来，对于任意 ID 序列，重新编码解码后的字符串，**不保证**得到相同 ID 序列；同一段字节可能有不同的 token 划分。

2.3 四个概念不能混在一起

概念	本课应采用的理解
Unicode 码点	字符的编号；不等于 UTF-8 中的一个字节。
UTF-8 字节	文本的编码单位，单个值在 0–255；一个码点可占多个字节。
Token / ID	分词器定义的片段及其编号；片段不一定是完整单词或字符。
Embedding	根据 ID 查到的可学习向量，属于语言模型参数。

> **分词器确定“用什么单位描述文本”；语言模型学习“这些单位怎样组合”。二者的训练不是同一个过程。**

例如，字符“你”的码点是 20320，而 UTF-8 字节为 $[228, 189, 160]$。字节级 BPE 可以保留这些单字节，也可以在训练中把常见组合合成更大的 token。

3 理解取舍：为什么不直接用字符、字节或单词？

本节目标：用词表大小与序列长度两条轴，理解 BPE 的动机。

3.1 三种直观方案，各自付出什么代价？

方案	好处	主要代价
字符级	容易理解和还原；比逐字节更紧凑。	覆盖广泛 Unicode 时词表较大；稀有字符难学，序列仍可能偏长。
字节级	基础词表只需 256 项；能表示任意合法 UTF-8 文本。	每个字节一个 token，序列较长；非 ASCII 字符会占多个 token。
整词级	常见词可用一个 token，序列较短。	词的种类多、长尾严重；固定词表会遇到未登录词，未知词标记可能丢失原文。
字节级 BPE	保留字节兜底，把高频片段压成较短序列。	需要学习词表和合并规则；效果依赖语料，仍有词表成本。

3.2 怎样衡量“文本被压短了多少”？

讲义采用的指标是**每 token 对应的 UTF-8 字节数**：

$$r(s) = \frac{B(s)}{T(s)}, \qquad B = \text{UTF-8 字节数}, \quad T = \text{token 数}.$$

对同一段非空文本，r 越大，token 序列越短。这个指标不等于压缩文件的存储压缩率，因为没有计入 ID 的存储位宽及词表开销。

例如“你好”：2 个码点、6 个 UTF-8 字节。字符级表示为 2 个 token，$r = 3$；纯字节级表示为 6 个 token，$r = 1$。空字符串的 B/T 是 $0/0$，需要单独处理。

3.3 为什么序列越短，不代表一切都更好？

补充解释：设词表大小为 V，隐藏维度为 d，序列长度为 T。

- **序列成本：**标准稠密自注意力的核心计算含 T^2 项；在其他条件相同时，缩短序列能显著减小这一部分开销。
- **词表成本：**嵌入表有约 Vd 个参数，输出词表投影也依赖 V；增大词表会增加相应成本。是否共享权重会影响实际参数总量。
- **统计成本：**词表中的稀有片段见得太少，就难以学到可靠表示。

> **BPE 的切入点：常见片段合得大一些，罕见片段拆得细一些。在序列长度、词表规模与覆盖能力之间取得实用折中。**

这里的 T^2 指自注意力相关部分，不能据此断言“token 数减半，整个模型训练就必然快四倍”。

4 核心例子：BPE 怎样从语料中学出词表？

本节目标：能够手算一次训练，并理解“合并”的对象。

4.1 先明确规则：合并最常见的相邻 token 对

本课介绍**字节级 BPE**。它从 256 个单字节 token 开始，每轮统计**当前序列**的相邻 token 对，选择最高频的一对，给它一个新 ID，再替换它的所有非重叠出现位置。BPE 也可从字符等单位开始；“BPE”这个名称本身不限定初始单位。

训练产物有两部分：**词表**保存“ID → 字节串”，**有序合并规则**保存“两个旧 ID → 新 ID”。词表用于解释结果，规则决定如何形成结果。

4.2 沿着同一句话，走三轮合并

训练文本使用官方讲义示例 `the cat in the hat`，共有 18 个 ASCII 字节。下文用 ␣ 显示真实空格，方括号表示一个 token，竖线仅用于分隔显示。

```
[t]|[h]|[e]|[ ]|[c]|[a]|[t]|[ ]|[i]|[n]|[ ]|
[t]|[h]|[e]|[ ]|[h]|[a]|[t]
```

轮次	被选中的相邻对	新 ID	结果与长度
1	$(116, 104)$：`t`+`h`	256	新片段 `th`；18 → 16
2	$(256, 101)$：`th`+`e`	257	新片段 `the`；16 → 14
3	$(257, 32)$：`the`+␣	258	新片段 `the`␣；14 → 12

每轮被选中的对都出现两次，且这两处互不重叠，因此每轮减少 2 个 token。最终序列为：

```
[the ]|[c]|[a]|[t]|[ ]|[i]|[n]|[ ]|[the ]|[h]|[a]|[t]
IDs: [258,99,97,116,32,105,110,32,258,104,97,116]
```

压缩比为 $18/12 = 1.5$；增加三个 token 后，词表大小为 $256 + 3 = 259$，原有 token 仍保留。

4.3 手算时最容易漏掉的细节

- 第二轮统计的是第一轮替换后的 token 序列，因此能形成 `th`+`e`；不是反复统计最初的字符对。
- 最高频可能并列。本例沿用讲义玩具程序“先遇到者优先”的顺序；不同的并列规则可能得到不同合并路径，作业须以手册为准。
- 配对计数与替换次数可能不同。`aaaaa` 中相邻 `aa` 有 4 个窗口，但一次从左到右非重叠替换得到 `[aa][aa][a]`，只有 2 次合并。

5 把训练结果用起来：编码与解码分别怎么做？

本节目标：分清学习规则与应用规则；能够解释新文本如何处理。

5.1 训练完成后，编码器不再学习新规则

将上一节保存的词表与规则固定下来，对新文本 `the quick brown fox` 编码。先转成 19 个 UTF-8 字节，再按已学的合并顺序应用规则：

阶段	序列前部的变化（后部保持单字节）	长度
初始	`[t][h][e][ ][q][u][i][c][k]...`	19
合并规则 1	`[th][e][ ][q][u][i][c][k]...`	18
合并规则 2	`[the][ ][q][u][i][c][k]...`	17
合并规则 3	`[the ][q][u][i][c][k]...`	16

最终得到：

```
[the ]|[q]|[u]|[i]|[c]|[k]|[ ]|[b]|[r]|[o]|[w]|
[n]|[ ]|[f]|[o]|[x]
```

本例中的“新词”不需要加入词表，也不必整体替换为未知词标记。已学过的 `the␣` 得到压缩，其他内容仍可由基础字节 token 表示。

> **训练阶段：根据语料统计学习词表与规则。**
> **编码阶段：对新文本应用固定规则，不重新统计“这句话里最常见的对”。**

5.2 为什么不能只看词表，随意选择最长片段？

BPE 的编码受**合并规则的优先级**约束。本课的简化实现按学习顺序遍历规则；较高效的实现可反复选取当前可用的、优先级最高的相邻对来合并。

因此，保存结果时要保存合并顺序，不能只保存一组无序规则，也不能把一般 BPE 简化成“总是从左到右取词表中的最长字符串”。

5.3 解码：先拼字节，再解释为文字

$$\text{ID 序列} \xrightarrow{\text{查词表}} \text{字节片段列表} \xrightarrow{\text{拼接}} \text{完整字节串} \xrightarrow{\text{UTF-8 解码}} \text{字符串}$$

例如 ID 258 对应字节串 `b"the "`。把它与后面的字节片段拼接，就恢复 `the quick brown fox`。

重要边界：一个 token 的字节片段不一定单独构成合法 UTF-8 字符。应先拼接整段字节，再解码。对于合法文本经编码得到的序列，能够还原；任意 ID 拼接出的字节串则不保证是合法 UTF-8。

6 从课堂玩具到实用分词器，还要补上什么？

本节目标：知道基础算法的边界，避免把演示实现当作完整工业实现。

6.1 预分词：先规定哪些边界不能跨越

预分词（pre-tokenization）先用规则把文本分成片段，之后 BPE 在各片段内进行。它限制可合并的位置，也影响最终结果；它不等于已经把每个完整单词确定为一个 token。

例如：若一个玩具预分词规则严格把单词与空格分开，那么 BPE 就不能学到跨越该边界的 `the␣`。第 4 节的课堂玩具示例没有这一限制；不能把它的输出直接当作所有实际分词器的输出。

6.2 特殊 token：为结构保留明确标记

普通文本之外，系统可能需要文档结束等特殊标记，例如 `<|endoftext|>`。它们通常有专门 ID，并在预处理时被识别和保护，不应像普通字节片段那样任意拆合。

如果文本中出现看起来像特殊标记的字样，需要由分词器接口约定它表示普通文本还是结构标记。具体策略属于实现规范，不能仅凭字面外观推断。

6.3 性能：规则相同，实现效率可以差很多

每次编码都遍历全部合并规则，是课堂中便于理解的做法。实际实现应避免大量无关扫描，重点关注当前出现的相邻对，并使用合适的数据结构更新状态。

第一课应优先掌握正确性：规则有顺序、替换不重叠、边界明确、字节可还原。高效训练与编码是进一步的工程工作；这里不展开完整作业实现。

6.4 数据分布：词表也是从语料中学来的

BPE 统计的是片段频率，不理解语言学意义。训练语料里常见的语言、领域和格式，往往更容易被较少 token 表达；较少出现的内容可能被拆得更细。

这会影响固定上下文窗口里能放进多少文本。例如“几千 token 的窗口”不等于固定字数，也不能套用一个对所有语言、代码和数字都成立的字符换算率。

> **分词器是一种表示与计算分配方案。它会影响效率，也会改变模型观察文本的方式；BPE 是实用启发式，并不保证找到最优切分。**

第一课还提出直接从字节学习表示的方向。复习时知道其动机即可：希望减少独立分词步骤，同时保留有效的分块和计算分配能力。它不是本课要求实现的内容。

7 一页速查：把本课压回一条主线

快速复习时先读这一页；遇到无法解释的环节，再回到对应章节。

7.1 用六句话重建本课

1. CS336 关心在给定资源下构建更好的模型，因此表示与效率必须一起考虑。
2. 模型处理的是 token 序列；分词器负责字符串与整数序列之间的转换，嵌入表负责 ID 到向量的映射。
3. 纯字节词表小但序列长，整词序列短但词表与未知词问题突出，广覆盖字符级也有长尾与规模成本。
4. 字节级 BPE 从 256 个基础 token 开始，反复合并当前最高频的相邻 token 对，保存词表和合并顺序。
5. 编码对新文本应用既有规则；解码查出字节片段、拼接后再做 UTF-8 解码。
6. 实用分词器还需要预分词、特殊 token 处理与性能优化，并受到训练语料分布影响。

7.2 四个数字与一个例子

记忆点	对应含义
256	不含特殊 token 时，基础字节词表的大小。
$r = B/T$	每 token 对应的 UTF-8 字节数；同一文本下越大越紧凑。
Vd	嵌入表参数量；词表变大并非没有代价。
T^2	标准稠密自注意力核心计算中的序列长度项。
`th` → `the` → `the␣`	讲义三次合并：训练文本从 18 个字节 token 变成 12 个 token。

7.3 易错点：看到这些说法，要能立即纠正

- **“一个 token 就是一个单词。”** token 可以是单词、子片段、空格、标点或部分字符字节。
- **“每来一句话，都重新训练 BPE。”** 编码使用固定规则；训练与使用阶段分开。
- **“BPE 每轮选最长片段。”** 训练选最高频相邻对；编码遵守已学合并优先级。
- **“每个 token 单独 UTF-8 解码就好。”** 片段可能不是完整字符，应先拼字节。
- **“词表越大就越好。”** 词表参数、输出计算与稀有片段学习都有成本。
- **“不同分词器的困惑度可以直接比较。”** token 单位不同，按 token 平均的损失与困惑度尺度也不同，需统一比较口径。

最后一条为补充提醒：本课只需知道评价指标依赖表示单位，具体评估方法将在后续课程展开。

8 自测：合上前文，检查自己是否真的理解

建议先独立作答，再看第 9 节。能用自己的话解释，比背术语更有用。

8.1 概念题：检查因果关系

Q1. 课程主线。为什么第一课讲分词时，要反复讨论计算预算？请说出“分词选择影响训练成本”的一条具体链路。

Q2. 表示层次。字符“你”的码点是 20320，UTF-8 字节是 $[228, 189, 160]$。纯字节分词器得到几个 token？BPE 一定也得到同样数量吗？

Q3. 算法动机。纯字节分词器既能还原文本，又只有 256 个基础 token，为什么还要学习 BPE？

Q4. 阶段区分。假设新文本中 `xy` 出现很多次，但训练时没有对应合并规则。编码时应不应该临时给 `xy` 分配一个新 token？为什么？

8.2 手算题：检查操作是否准确

Q5. 合并与压缩比。从 18 个字节开始，依次合并 `t+h`、`th+e`、`the+` 空格；每轮被选对有两个非重叠出现位置。最终有几个 token？压缩比与词表大小分别是多少？

Q6. 重叠替换。在序列 `[a][a][a][a][a]` 中，`(a,a)` 有几个相邻窗口？把每对合并为 `A`，一次从左到右非重叠替换的结果是什么？

Q7. 解码顺序。词表中的三个 token 分别存放单字节 228、189、160。为什么不能要求三个 token 都能各自解码成一个汉字？正确流程是什么？

8.3 迁移题：检查是否会判断取舍

Q8. 成本判断。某次扩大词表后，同一文本的 token 数从 1000 减至 500。标准稠密自注意力中的 T^2 项如何变化？为什么不能由此断言整个训练快四倍？

Q9. 边界判断。如果预分词把单词与空格严格分开，第 4 节的 token `the␣` 还能通过片段内 BPE 学出来吗？这说明分词结果由哪些部分共同决定？

> **掌握标准：能独立讲清“为什么需要 BPE”，手算三轮合并，并分清训练、编码和解码。若这三点还模糊，优先重读第 3–5 节。**

延伸观察：选一段英文、一段中文和一段代码，用同一分词器观察切分。记录空格、数字、标点和罕见片段的差异；不要把观察到的个例当成所有分词器的通则。

9 参考答案与资料来源

答案用于核对关键点，不要求逐字背诵。

9.1 参考答案

A1. 分词改变序列长度，进而改变注意力等计算成本与固定窗口可容纳的文本量；在固定预算下，会影响能处理多少内容。词表增大也有额外成本。

A2. 纯字节分词器输出 3 个 token。BPE 的数量取决于学到的合并规则，可能保留 3 个，也可能合成更少 token。

A3. 纯字节序列较长。BPE 为高频字节片段提供更紧凑的表示，同时保留基础字节作为兜底。

A4. 不应该。编码阶段必须使用已固定的词表和规则；模型也只为既定词表配置了嵌入与输出，不能临时增加一个陌生 ID。

A5. 最终 $18-2-2-2=12$ 个 token；$r=18/12=1.5$；词表有 $256+3=259$ 项，不含额外特殊 token。

A6. 有 4 个相邻窗口，但只能非重叠地替换两对。结果是 `[A][A][a]`，还剩 3 个 token。

A7. 三个单字节只是同一个 UTF-8 字符的组成部分，各自并非完整字符。先拼接为 $[228, 189, 160]$，再解码为“你”。

A8. $500^2/1000^2=1/4$，该项变为原来的四分之一。整体还受其他层计算、词表投影、内存访问、实现效率等因素影响。

A9. 不能跨该边界学出来。最终结果由基础单位、训练语料、预分词规则、合并顺序及特殊 token 约定等共同决定。

9.2 阅读范围与来源

本资料依据 **Spring 2026 第 1 课官方可执行讲义**重新组织，制作时已对照讲义与示例核对记录。是复习笔记，不是录像逐字稿；未声称观看了完整录像或逐篇精读了所有引用论文。

下一 token 概率公式、ID 与嵌入的关系、成本量级说明以及自测题属于为入门补充的解释。BPE 手算采用官方讲义的玩具示例与并列处理顺序，不替代当前作业手册的详细规范。

- 官方课程主页与 Schedule：课程版本、课次与主题。
- 第 1 课讲义源码：动机、五模块总览、分词比较与 BPE 演示。
- 在线可执行讲义：用于回到课堂结构与代码示例。
- 官方讲义仓库；Assignment 1 仓库：进一步学习的入口。

公开主分支可能更新。原始资料可通过以上官方链接访问；本笔记整理日期为 2026 年 10 月 23 日。