STANFORD CS336 · LANGUAGE MODELING FROM SCRATCH

第 03 课复习资料

架构与超参数

目录

1 先定位：怎样选出值得训练的 Transformer？ 2

2 搭好主干：归一化、门控与残差连接 4

3 编入顺序：RoPE 为什么能表达相对位置？ 7

4 分配预算：宽度、头数、深度和词表 9

5 控制推理成本：KV 缓存与注意力变体 11

6 让训练稳定：优化动态与两处 softmax 14

7 一页速查：把本课压缩成一条链 16

8 自测：能否脱离笔记说清楚？ 17

9 参考答案与资料来源 18

阅读主线：搭起预测链路 → 稳住残差与特征变换 → 编入位置 → 分配模型尺寸 → 控制推理成本 → 稳定训练。

1 先定位：怎样选出值得训练的 Transformer？

1.1 接上前两课：表示、资源之后，轮到结构

第一课把文本变成 token，第二课学会计算张量、FLOPs 和显存。本课继续追问：有了这些积木，应该怎样连接、各做多大，才能把预算用在有效且稳定的学习上?

> **本课的核心问题：给定数据、训练预算和推理需求，怎样选择 Transformer 的结构与超参数，并判断一个改动是否值得？**

课件通过大量模型和消融实验归纳经验。复习时应记住**选择背后的机制、成本和证据**，而不是记住每个模型的配置表。某个方案被广泛采用，是一个有用的起点；要确认它适合自己的任务，仍需控制变量的实验。

1.2 先认清完整链路，再看局部变化

本笔记以自回归、仅解码器语言模型为主，原始 Transformer 的编码器--解码器结构用作对照。整体计算是：

$$\text{token ID} \longrightarrow \text{嵌入向量} \longrightarrow L \text{ 个 Transformer 块}$$

$$\longrightarrow \text{最终归一化} \longrightarrow \text{词表 logits} \longrightarrow \text{下一 token 概率.}$$

每个块有两个核心子层：**注意力**让不同位置交换信息；**FFN / MLP** 对每个位置分别进行特征变换。残差连接把子层输出加回原表示。FFN 的参数在位置之间共享，但它本身不混合不同位置。

设计问题	本课的回答路径
深层信号	比较 Pre-norm、Post-norm 与分支归一化。
特征变换	比较 LayerNorm / RMSNorm、普通 FFN / 门控 FFN。
顺序与位置	从加法位置编码走到旋转 Q、K 的 RoPE。
尺寸与预算	联合选择宽度、深度、FFN、头维度和词表。
生成成本	用 KV cache、GQA / MQA 和局部注意力减少搬运。
训练稳定性	结合优化设置、z-loss、QK-norm 与 soft-capping。

复习路线：第 2–6 节沿同一模型逐步展开；第 7 节是一页速查，第 8 节是自测。

1.3 贯穿例子：一个可以手算的小型模型

以下数字用于理解形状与成本，不是实际训练推荐配置。所有线性层无偏置，各层参数独立。

固定 batch 大小 $B = 2$、当前序列长度 $n = 4$、词表大小 $V = 64$、模型宽度 $d = 24$、层数 $L = 2$。初始采用 $h_q = h_{kv} = 6$ 个头，每头维度 $d_h = 4$；SwiGLU 中间宽度 $m = 64$。后面只在明确说明时改变这些设置。

令 $X \in \mathbb{R}^{B\times n\times d}$ 为某一层输入。现代串行 Pre-norm 块可写成

$$U = X + \mathrm{Attn}(\mathrm{Norm}_1(X)), \qquad Y = U + \mathrm{FFN}(\mathrm{Norm}_2(U)).$$

两次相加两侧的 shape 都必须是 (B, n, d)。归一化、注意力和 FFN 的内部宽度可以不同，但输出要回到残差流的宽度 d。

1.4 先把普通多头注意力展开一次

由归一化后的输入分别投影出 Q, K, V_a，这里用 V_a 表示 value 张量，以区别词表大小 V。本例三个投影均为 24×24，然后拆成六个头：

$$(2, 4, 24) \longrightarrow (2, 6, 4, 4) \quad \text{轴顺序为 batch、head、position、feature。}$$

对每个头，先按位置旋转 Q, K，得到 $\widetilde{Q}, \widetilde{K}$；再计算

$$S = \frac{\widetilde{Q}\widetilde{K}^{\mathsf{T}}}{\sqrt{d_h}} + M, \qquad A = \mathrm{softmax}_{\text{key position}}(S), \qquad H = AV_a.$$

S, A 的 shape 为 $(2, 6, 4, 4)$；最后两个轴是 query 位置和 key 位置，**不是两个特征轴**。因果掩码 $M_{ij} = 0$ 当 $j \le i$，否则为 $-\infty$，防止当前位置看到未来。拼接六个 H 后，经输出投影 W_O 回到 $(2, 4, 24)$。

1.5 训练并行，为何生成仍有先后？

训练时已知整段真实文本，可以一次计算所有位置，但每个位置仍受因果掩码约束。位置 i 的 logits 用来预测 x_{i+1}；输入和标签要错开一位。

普通逐 token 生成时，下一个输入取决于刚生成的结果，所以不同生成步之间存在依赖。第 5 节将看到：**KV cache 省去旧位置的重复投影，却没有消除新 query 对历史 K、V 的读取**。

> **先记住主干：同一个 (B, n, d) 残差流，依次接收注意力的跨位置信息和 FFN 的逐位置特征变换。后面的设计都在改变这条链路的某一部分。**

2 搭好主干：归一化、门控与残差连接

本节目标：分清归一化“放在哪里”和“怎样计算”，再理解 FFN 为什么多出一个门。

2.1 Pre-norm 与 Post-norm：先看加号在哪里

用 F 代表一个注意力或 FFN 子层，N 代表归一化。忽略 dropout 后：

$$\text{Post-norm:}\quad y = N(x + F(x)),$$
$$\text{Pre-norm:}\quad y = x + F(N(x)).$$

Post-norm 把相加后的整条残差流再归一化；Pre-norm 把归一化放进分支，保留 $x \to y$ 的直接通路。为理解反向传播，可写出局部雅可比：

$$J_{\text{pre}} = I + J_F J_N, \qquad J_{\text{post}} = J_N(I + J_F).$$

前者有显式的恒等项，后者的直接通路也经过归一化。这说明了 Pre-norm 为什么有利于深层信号传播，**不等于证明它永不梯度爆炸或总有更低损失**。

Xiong 等和 Nguyen、Salazar 的研究观察到归一化位置会影响初始化梯度、梯度尖峰及学习率选择。部分实验能去掉 warmup；迁移到大模型时，更稳妥的结论是 **Pre-norm 提供了较好的稳定性起点**，而不是一律取消 warmup。

2.2 分支末尾也能归一化：别只看“post”这个词

如果归一化作用于子层输出、但位于残差相加之前，则是

$$y = x + N(F(x)).$$

这仍然保留未经归一化的残差直通路径，与 $N(x+F(x))$ 不同。如果分支两端都归一化，则可写成

$$y = x + N_{\text{out}}(F(N_{\text{in}}(x))).$$

课件用 OLMo 2、Gemma 2 等说明这些变体。判断结构时应追踪**归一化在相加之前还是之后**，不要仅凭模型说明中的 Pre / Post 命名猜测。典型 Pre-norm 模型在所有块之后还会放一个最终归一化。

2.3 第二个独立问题：LayerNorm 还是 RMSNorm？

前面讨论的是位置；下一页讨论归一化本身的函数。**Pre-norm 可以搭配 LayerNorm，也可以搭配 RMSNorm**。把二者当成互斥方案，会混淆两个独立的设计维度。

> **保留残差直通路径是结构上的考虑；归一化统计量、精度和算子实现则决定每次归一化的行为与成本。**

2.4 把两个归一化公式写完整

对单个 token 的 d 维向量 x，统计量沿**特征轴**计算，不跨 batch 或序列位置：

$$\mu = \frac{1}{d}\sum_{i=1}^{d} x_i, \qquad \sigma^2 = \frac{1}{d}\sum_{i=1}^{d}(x_i-\mu)^2.$$

$$\mathrm{LayerNorm}(x)_i = \gamma_i \frac{x_i-\mu}{\sqrt{\sigma^2+\epsilon}} + \beta_i, \qquad \mathrm{RMSNorm}(x)_i = \gamma_i \frac{x_i}{\sqrt{\frac{1}{d}\sum_j x_j^2+\epsilon}}.$$

γ 是可学习缩放，β 是偏置，ϵ 用于数值稳定。现代常用的无偏置 RMSNorm 不减均值、不加 β；LayerNorm 也可以配置成无偏置。

注意口径：RMS 是均方根，不能直接写成 $\|x\|_2$。忽略 ϵ 时，$\mathrm{RMS}(x) = \|x\|_2/\sqrt{d}$。课件第 14 页的简写容易漏掉这个因子，实际实现应保留平均。

2.5 一个两维切片，立即看出差异

为便于手算，取独立的小例子 $x=(3,4)$，令 $\gamma=(1,1)$、$\beta=0$，暂忽略 ϵ。

$$\mathrm{LN}(x) = (-1,1), \qquad \mathrm{RMSNorm}(x) = \frac{(3,4)}{\sqrt{12.5}} \approx (0.8485, 1.1314).$$

LN 的归一化部分均值为零；RMSNorm 的输出不必均值为零。LN 对所有坐标同时加常数有不变性；RMSNorm 通常没有。二者都针对尺度，忽略 ϵ 时对正的整体倍数具有相应不变性。

2.6 少算一点，为什么可能快不少？

这正好接上第二课：**FLOPs 占比不等于时间占比**。归一化涉及归约、读写激活和内核启动，即使 FLOPs 很少，也可能受到带宽限制。RMSNorm 减少均值相关计算，给高效实现提供机会；收益取决于形状、融合方式和硬件。

课件引用的一个 BERT 编码器层测量中，统计归一化约占 0.17% 的 FLOPs，却占 25.5% 的时间。这是**特定实验**，用于说明瓶颈差异，不能当成所有大模型的固定比例。

2.7 去掉 bias：省的不只是几个参数

线性层 $xW+b$ 中，矩阵有 $O(d^2)$ 参数，偏置通常只有 $O(d)$。去掉偏置能简化计算与搬运，一些模型也报告稳定性收益；但不能据此声称总显存大幅降低。应结合实际实现测时间，再看质量是否保持。

2.8 从普通 FFN 到 SwiGLU：多一条投影，再逐元素相乘

用 m 表示 FFN 的中间宽度。普通无偏置 FFN 为

$$\mathrm{FFN}(x) = \phi(xW_1)W_2, \qquad W_1 \in \mathbb{R}^{d\times m}, \quad W_2 \in \mathbb{R}^{m\times d}.$$

ReLU 是 $\max(0, z)$；GELU 是 $z\Phi(z)$，其中 Φ 是标准正态分布函数。门控版本先做两条投影，再把对应坐标相乘：

$$\mathrm{SwiGLU}(x) = \big[\mathrm{SiLU}(xW_g) \odot (xW_u)\big]W_d, \qquad \mathrm{SiLU}(z) = z\ \mathrm{sigmoid}(z).$$

$W_g, W_u \in \mathbb{R}^{d\times m}$，$W_d \in \mathbb{R}^{m\times d}$。这里的“门”是内容相关的特征调制，**不是在 token 之间做注意力，也不是 0/1 开关**。用 GELU 或 ReLU 替换 SiLU，就得到 GeGLU 或 ReGLU。

本例中，两条投影都把 $(2, 4, 24)$ 变成 $(2, 4, 64)$，相乘后仍是 $(2, 4, 64)$，再映射回 $(2, 4, 24)$。普通 FFN 有 $2dm$ 个权重，门控 FFN 有 $3dm$ 个。

$$2d(4d) = 8d^2 = 3d\left(\frac{8}{3}d\right).$$

因此从普通 FFN 的 $m = 4d$ 换成门控 FFN 时，把宽度乘 $2/3$，能近似保持参数和主要矩阵乘法预算。本例 $m : 96 \to 64$，两者都是 4608 个权重。保持 $m = 96$ 不变则会多出 50% 的 FFN 权重，不能称为同预算比较。

2.9 串行与并行块：FFN 是否读取注意力的新结果？

串行结构是前面的 $U = X + \mathrm{Attn}(N_1(X))$，再计算 $Y = U + \mathrm{FFN}(N_2(U))$。并行变体可写成

$$Y = X + \mathrm{Attn}(N(X)) + \mathrm{FFN}(N(X)).$$

两条分支读取同一输入，可能共享归一化并融合输入投影，减少依赖和搬运。代价是 FFN 不再直接读取本块注意力更新后的 U。这是**模型结构变化**；不能把串行模型随意改成并行而期待输出相同，也不意味着必须放到两张 GPU 上。

实践起点：串行残差块、分支内归一化、RMSNorm、无偏置和 SwiGLU 是一个合理基线。门控收益有实验支持，但具体吞吐和质量仍需在同预算下比较。

3 编入顺序：RoPE 为什么能表达相对位置？

本节目标：从“把位置加进向量”走到“让 Q、K 的内积依赖位置差”。

3.1 位置编码解决的是什么缺口？

普通注意力的内容打分只看到 query 和 key 向量；因果掩码规定了能看谁，却没有直接给出位置差。位置编码让模型更容易区分相同内容出现在不同顺序或距离的情形。不要把“没有显式位置编码”简单等同于“因果模型完全无法感知顺序”。

方案	位置如何进入计算	需要理解的取舍
固定正弦	输入中加固定 PE_i。	可计算任意位置，但超出训练长度的效果仍需验证。
绝对位置	输入中加可学习的 u_i。	直接表达位置，通常受训练表长及扩展方式约束。
相对位置项	在注意力打分中加入位置差相关的偏置或向量。	是一类方法；T5 的桶化偏置与向量式相对编码不同。
RoPE	投影后按位置旋转 Q、K。	通过内积自然引入位置差，无需逐位置学习向量表。

3.2 为什么加法不直接满足目标？

假设先把内容向量与位置向量相加，其内积包含

$$(x + PE_i)^\mathsf{T}(y + PE_j) = x^\mathsf{T}y + x^\mathsf{T}PE_j + PE_i^\mathsf{T}y + PE_i^\mathsf{T}PE_j.$$

中间两项混合了内容和绝对位置。因此即使某些正弦项能表达位置差，整体也不会自动只依赖 $j - i$。RoPE 希望在给定内容 Q、K 后，位置的作用能整理为相对位移。

3.3 先用二维旋转理解它

把一个头的特征两两分组。对其中一对坐标，用旋转矩阵

$$R(\alpha) = \begin{pmatrix} \cos\alpha & -\sin\alpha \\ \sin\alpha & \cos\alpha \end{pmatrix}$$

编码位置 p：$q'_p = R(p\theta)q_p$，$k'_p = R(p\theta)k_p$。不同坐标对使用不同频率 θ；同一对的 Q、K 使用一致约定。旋转保持长度，改变方向，使位置进入后续相似度计算。

RoPE 的关键不是又出现了 sin / cos，而是用它们旋转投影后的 Q、K；与把 sin / cos 向量直接加到输入上的做法不同。

3.4 核心推导：绝对位置如何消掉？

以下把单个头的 q、k 写成列向量；与前面的批量行向量实现只是记号不同。

利用 $R(\alpha)^{\mathsf{T}} = R(-\alpha)$ 以及旋转角相加：

$$\begin{aligned}(R(i\theta)q_i)^{\mathsf{T}}(R(j\theta)k_j) &= q_i^{\mathsf{T}}R(i\theta)^{\mathsf{T}}R(j\theta)k_j \\ &= q_i^{\mathsf{T}}R((j-i)\theta)k_j.\end{aligned}$$

两边位置同时平移 c 后，$(j+c)-(i+c) = j-i$，所以给定内容向量时该内积不变。这并不声称整个带边界、掩码和上下文的模型对任何位置移动都完全不变。

对于 d_h 为偶数的完整旋转，一个常见原始设置是

$$\theta_r = 10000^{-2r/d_h}, \qquad r = 0, \ldots, d_h/2 - 1.$$

本例 $d_h = 4$，两对坐标的频率分别为 1 和 0.01。这是一个常见频率基数，**不是永远固定的超参数**；实际模型还会调整基数、缩放或只旋转部分维度。

3.5 手算与实现：无需构建大旋转矩阵

另取二维演示 $q = (1, 0)$、$k = (1, 1)$、$\theta = \pi/2$。位置 $(i, j) = (0, 1)$ 时，$q' = (1, 0)$、$k' = (-1, 1)$，内积为 -1。把位置改成 $(2, 3)$，得到 $q' = (-1, 0)$、$k' = (1, -1)$，内积仍为 -1。

对每一对坐标 (a, b)，直接算 $a\cos\alpha - b\sin\alpha$ 和 $a\sin\alpha + b\cos\alpha$ 即可。下面是成对相邻排列的示意接口，省略框架细节：

```
# x is q or k: (B, heads, n, head_dim)
# angles: (n, head_dim // 2), using true positions
a, b = x[..., 0::2], x[..., 1::2]
even = a * cos - b * sin
odd  = a * sin + b * cos
x_rotated = interleave(even, odd)
```

不同实现也可能把前后半段配对，使用前必须核对权重和布局约定，不能只看公式形似就互换。

3.6 落到模型时，检查三个接口

通常在**每层注意力的 Q、K 投影之后**应用 RoPE，value 保持原样。使用 KV cache 时，新 token 要沿用真实位置偏移，旧 key 若已旋转就不能再重复旋转。RoPE 可以计算更远位置，**不等于自动获得任意长度的可靠外推**。

4 分配预算：宽度、头数、深度和词表

本节目标：把“大家常这样设”与“形状必须这样设”分开，用参数账解释常见比例。

4.1 FFN 宽度：先问两矩阵还是三矩阵

普通 FFN 的 $m \approx 4d$、门控 FFN 的 $m \approx \frac{8}{3}d$ 都是有用起点。实际配置会按硬件友好倍数取整，也会在容量分配上作调整。8/3 来自前面的**同预算推导**，不是 SwiGLU 的数学定义。

课件用 T5-11B 的 $d = 1024, m = 65536$ 说明 $m/d = 64$ 仍能训练；但它是编码器--解码器模型中的特定选择，不能直接推广为现代仅解码器模型的最优比例。Kaplan 等的实验显示某些形状比例有较宽的有效区间，结论也依赖规模、数据和比较口径。

4.2 头数乘头维度必须等于模型宽度吗？

设 query 头数为 h_q，总注意力宽度 $a = h_q d_h$。普通 MHA 可采用

$$W_Q, W_K, W_{V_a} \in \mathbb{R}^{d\times a}, \qquad W_O \in \mathbb{R}^{a\times d}.$$

只要投影与 reshape 一致，a 可以不等于 d。**只有当你预先把投影输出固定为 d 并均分成头时，才要求 $h_q \mid d$**。Q、K 的单头维度需要匹配才能做内积；本笔记为简洁也让 value 头维度相同。

因此 $h_q d_h = d$ 是常见预算选择，不能当成架构定理。例如本例仍取 $d = 24, h_q = 6$，若把 d_h 从 4 改成 8，则 $a = 48$，MHA 投影参数由 $4d^2 = 2304$ 增为 $4da = 4608$；输出照样可以回到 24 维。

4.3 把小模型的参数账合起来

回到原始例子 $d = 24, h_q = 6, d_h = 4, m = 64$。暂只计算普通 MHA 与 FFN 的大矩阵：

$$N_{\text{attn}} = 4d^2 = 2304, \qquad N_{\text{FFN}} = 3dm = 4608,$$

$$N_{\text{block}} = 6912 = 12d^2, \qquad N_{\text{blocks}} = L \cdot 6912 = 13824.$$

输入嵌入和输出投影**不共享**时还需 $2Vd = 3072$；每块两个带缩放的 RMSNorm，加最终一个，共 $(2L+1)d = 120$。总计 17016 个参数。若共享输入输出权重，则总计 15480。这两个数字都包括归一化，不含任何 bias。

> **“约 $12Ld^2$ 个参数”需要普通 MHA、头总宽度等于 d、匹配预算的 FFN 等条件；它不自动包含词表，也不能直接套给所有 GQA 模型。**

4.4 更深还是更宽：参数相近，系统行为仍会不同

当每层结构比例固定且大矩阵主导参数时，$N \propto Ld^2$。若把深度翻倍，要维持同样的主干参数量，宽度约缩为 $d/\sqrt{2}$；这个关系是**预算近似**，不是质量相等的保证。

加深增加串行依赖，单个请求不能跳过前一层去计算后一层；加宽更容易把大矩阵分到多设备，但也影响通信和单层激活。课件中 d/L 常见约 100–200，同时存在明显例外。小模型、不同架构与硬件不必落在此范围。

Kaplan 的损失--参数比较和 Tay 等的预训练、微调与速度实验提示：**同参数、同 FLOPs、同耗时不是同一个比较问题**。选择深宽比例时，应同时测验证质量、训练吞吐和生成延迟。

4.5 词表大小：第一课的选择，会在这里收到账单

扩大词表常能缩短同一文本的 token 序列，但会增大嵌入表和输出层。单张表有 Vd 个权重；完整输出投影每个位置约需 $2dV$ FLOPs。共享输入输出权重能省参数，**不会消除词表 logits 的计算**。

词表变大后	需要一起考虑的变化
序列可能变短	同一原始文本的注意力成本、位置数和有效上下文发生变化。
每个 token 更贵	输出投影、softmax 与模型状态可能增大。
语言覆盖改变	多语种、代码、数字和长尾片段的切分质量可能变化。
评价单位改变	不同分词器的每 token 损失不能直接当作公平质量比较。

课件给出的历史样本大致是：单语模型常用数万词表，多语或产品模型常用十几万至二十多万。它们是观察范围，**不是单语上限，也不是多语最低要求**。应固定原始文本或使用一致评价口径，比较最终资源与质量。

4.6 怎样从一组默认值走向自己的配置？

先保留可靠基线，再选真正影响目标的变量。长上下文生成受限时，先检查 KV cache 与注意力模式；小模型词表占比过高时，先检查 Vd；出现训练尖峰时，先检查数值与优化动态。不要在每项上同时做微小改动，最后却无法解释收益来自哪里。

承上启下：模型参数账主要随结构固定；生成时还有一份随上下文增长的 KV 缓存账。下一节从这份账出发理解注意力变体。

5 控制推理成本：KV 缓存与注意力变体

本节目标：分别看清“共享多少组 K、V”和“每个 query 看哪些位置”两种节省。

5.1 KV cache：哪些结果值得跨步保留？

因果生成时，已有 token 在各层的 K、V 不随新 token 到来而改变，可以缓存。每一步只计算新 token 的投影，把新 K、V 追加进去；新 query 对缓存的历史 K 打分，再对 V 加权。旧 query 不参与未来位置的计算，因此通常无需缓存旧 Q。

对 L 层、B 条长度为 n 的序列，设 KV 头数为 h_{kv}，每个元素 s byte，忽略对齐和管理开销：

$$\boxed{M_{\mathrm{KV}} = 2LBnh_{kv}d_h s \text{ byte.}}$$

最前面的 2 来自 K、V 两份。本式描述**当前驻留容量**，不是整个生成过程的累计读取量，也不是训练时为反向保存的全部激活。

5.2 MHA、MQA、GQA：query 头可以保持不变

方案	KV 头数	共享关系
MHA	$h_{kv} = h_q$	每个 query 头有自己的一组 K、V。
MQA	$h_{kv} = 1$	所有 query 头共享一组 K、V；每组仍有 d_h 个特征。
GQA	$1 < h_{kv} < h_q$	query 头分组，同组共享 K、V，通常要求 h_q 能被 h_{kv} 整除。

“MQA 只剩一个维度”的口头说法容易误导：减少的是 **KV 头的数量**，不是把每个 key 变成一个标量。本例仍有六个 query 头；GQA 可令 $h_{kv} = 2$，每三个 query 头共享一组 K、V。

5.3 回到同一个例子：缓存与参数分别省多少？

本例 $L = 2, B = 2, n = 4, d_h = 4$，缓存采用 bf16，$s = 2$。同时，注意力的四类投影参数为

$$N_{\mathrm{attn}} = 2d(h_q d_h) + 2d(h_{kv} d_h).$$

项目	MHA	GQA	MQA
h_q/h_{kv}	6/6	6/2	6/1
KV 缓存	1536 byte	512 byte	256 byte
每层投影权重	2304	1536	1344

缓存按 h_{kv} 成比例减少；Q 与输出投影仍在，所以注意力参数和总 FLOPs 不会按相同比例下降。GQA 是质量与效率之间的调节旋钮，效果需要训练和评估验证。

5.4 为什么训练不慢，逐 token 生成却可能受带宽限制？

补充推导：沿用课件及 MQA 原论文的简化模型。以下 O 记号忽略常数、dtype 字节宽度与内核细节。

为比较两种执行方式，暂取普通 MHA，$h = h_q = h_{kv}$、$d = hd_h$，并假设 $n \le d$。一次处理全部位置时，大量 query 可以复用投影权重与 K、V；逐步生成时，同样的历史 K、V 会被反复读取。

执行方式	算术操作量	访问元素量的简化估算
整段处理	$O(Bnd^2 + Bn^2d)$	$O(Bnd + Bhn^2 + d^2)$
逐步生成 n 次	$O(Bnd^2 + Bn^2d)$	$O(Bn^2d + nd^2)$

表中第二行是**生成 n 个位置的累计量**。单步历史长度为 t 时，读 KV 约 $O(Btd)$；求和 $\sum_{t=1}^{n} t = O(n^2)$，就得到 $O(Bn^2d)$。每步还可能重新读取模型权重，因此出现 $O(nd^2)$。

在 $n \le d$ 时，算术量可简化为 $O(Bnd^2)$。用访问量除以它，得到“每次算术操作需要访问多少元素”的量级：

$$\begin{aligned} \text{整段：} &\quad O\left(\frac{1}{d} + \frac{n}{d\,d_h} + \frac{1}{Bn}\right), \\ \text{增量 MHA：} &\quad O\left(\frac{n}{d} + \frac{1}{B}\right), \\ \text{增量 MQA：} &\quad O\left(\frac{1}{d} + \frac{n}{dh} + \frac{1}{B}\right). \end{aligned}$$

课件将第一式进一步用 $O(1/d_h + 1/(Bn))$ 表示上界。**算术强度是它的倒数方向**；换算成 FLOPs/byte 还需乘上具体计数常数与 dtype 宽度。不能直接把这个量级当成精确硬件指标。

5.5 从公式读出两条不同的优化方向

增大 batch 能改善权重搬运项 $1/B$；减少 KV 头数能改善历史缓存搬运项。GQA 处于 MHA 与 MQA 之间：在相同简化假设下，历史项约由 n/d 缩为 $nh_{kv}/(dh_q)$。

这些估计假设普通物化注意力张量，并用简单的读写模型看趋势。融合内核、FlashAttention、缓存命中、并行切分都会改变实际 I/O。长序列 $n > d$ 时也不能再忽略 Bn^2d 的计算。**最终判断仍要回到第二课的 roofline 与实测吞吐**。

5.6 另一条轴：减少每个 query 可见的位置

GQA 改变的是头的共享关系；稀疏或滑动窗口注意力改变的是**连接模式**。完整因果注意力让位置 i 看到 $0,\dots,i$，总连接数约为 $n(n+1)/2$。若窗口大小 w 表示含当前位置的最多 w 个位置，则

$$\max(0, i-w+1) \le j \le i.$$

当 $w \ll n$ 时，连接数为 $O(nw)$；QK 与加权求和的计算由 $O(Bn^2d)$ 变为 $O(Bnwd)$。在精确支持该窗口的实现中，局部层的 KV 缓存也只需保留最近 w 个位置。

5.7 少连边的代价：远距离信息怎样过来？

本例 $n=4$，完整因果图有 $1+2+3+4=10$ 条允许边；若 $w=2$，则有 $1+2+2+2=7$ 条。位置 3 无法在这一层直接读取位置 0，但可以通过多层局部信息传递间接接收更远信息。

每层固定窗口最多扩展 $w-1$ 个过去位置；L 层后的理论感受野约为 $1+L(w-1)$。**可达不等于能够高保真保留信息**，远距离检索仍可能受到影响。稀疏 Transformer 还可以设计跨步、固定全局位置等连接，而不只有相邻窗口。

5.8 混合局部层与全局层

课件展示了把若干局部层与一个完整注意力层交替堆叠的做法：局部层以较低成本处理邻域，全局层提供直接的远距离通路。不同模型的层比例、RoPE 与 NoPE 配置不同，不存在统一的固定配方。

设全局层数为 L_g、局部层数为 L_ℓ，各层使用相同 KV 头数，则简化缓存为

$$M_{\mathrm{KV}} \approx 2Bh_{kv}d_h s\left[L_g n + L_\ell \min(n, w)\right].$$

只要仍有全局层，缓存就不能一律截断到 w。同理，固定比例的全局层在渐近意义下仍保留二次注意力项；混合架构降低常数成本，不自动变成全模型线性复杂度。

5.9 两种节省可以组合，但不要混淆机制

GQA 可与窗口注意力一起使用；前者少存、少搬 KV 头，后者少连位置。FlashAttention 则通过计算组织减少物化与搬运，可保持完整注意力的数学连接；它不等同于稀疏注意力。课件提到的 MLA、SSM 和其他混合方案作为延伸入口，具体机制留到后续课程。

> **选注意力方案时，先问瓶颈是权重搬运、KV 容量、历史读取还是成对计算，再决定调 batch、KV 头数、窗口或实现方式。**

6 让训练稳定：优化动态与两处 softmax

本节目标：把正则化、数值实现和结构稳定性联系起来，避免只看最终损失。

6.1 数据很多，为什么还会用 weight decay？

大规模预训练中，一些模型不使用 dropout，却仍使用 weight decay。数据规模大、重复轮数少，可能减少传统过拟合压力；这**不代表模型不会记忆，也不代表小数据微调可以照搬设置**。论文没有报告 dropout 时，也不能断言它必然为零。

以解耦衰减的 AdamW 形式看，若 u_t 是自适应梯度更新方向：

$$\theta_{t+1} = (1 - \eta_t \lambda)\theta_t - \eta_t u_t.$$

衰减量与学习率 η_t、衰减系数 λ 和当前权重共同有关。关于 weight decay 的研究在所测试的近单遍语言模型训练中，观察到它可以改善优化动态和低精度训练稳定性；作用不必表现为缩小训练--验证差距。**这不是所有任务中“正则化无用”的定理**。

因此应把 dropout、weight decay、学习率日程和参数分组一起看；不能只因某个模型用了 0.1，就给所有参数、所有训练阶段照抄相同衰减。

6.2 先把 softmax 本身算稳定

模型有两处重要 softmax：注意力位置分布与输出词表分布。给定一行有限 logits z，设 $c = \max_i z_i$，使用

$$\operatorname{softmax}(z)_i = \frac{e^{z_i - c}}{\sum_j e^{z_j - c}}, \qquad \log Z = c + \log \sum_j e^{z_j - c}.$$

例如 $(1000, 1001)$ 直接取指数会有溢出风险，减去 1001 后可得到约 $(0.2689, 0.7311)$。训练交叉熵宜用稳定的 log-softmax / logsumexp。还要保证每一有效 query 至少有一个未屏蔽 key，防止全 $-\infty$ 行导致无效运算。

6.3 输出 z-loss：约束交叉熵看不到的整体漂移

对目标 token y，$\ell_{\mathrm{CE}} = -z_y + \log Z$。加上同一个常数不会改变 softmax 概率，但会改变 $\log Z$。常见 z-loss 写成

$$\ell = \ell_{\mathrm{CE}} + \alpha(\log Z)^2, \qquad \alpha > 0.$$

它把输出 log-partition 拉向零，约束 logits 的整体偏移；**不是把每个 logit 都压到零，也不是 MoE 路由负载均衡损失**。PaLM 报告使用 10^{-4}，其他模型有不同设置。实现时应使用上面的原始 $\log Z$，不能漏掉减最大值时的补偿项 c。

6.4 QK-norm：控制进入注意力 softmax 的向量

即使已使用 $1/\sqrt{d_h}$ 缩放，训练中的 Q、K 范数仍可能增大，导致注意力 logits 极端。QK-norm 在打分前归一化 Q、K，例如

$$\widehat{q}_i = \mathrm{RMSNorm}(q_i), \qquad \widehat{k}_j = \mathrm{RMSNorm}(k_j), \qquad s_{ij} = \frac{\widehat{q}_i^{\top}\widehat{k}_j}{\sqrt{d_h}}.$$

这是机制示意：实际实现需要明确归一化轴、缩放参数，以及与 RoPE 的先后关系。使用逐维可学习缩放时，归一化和旋转一般不能任意交换。**RMSNorm 也不是单位 L2 归一化**，不能直接把这个式子称为范围在 $[-1, 1]$ 的余弦相似度。

6.5 Soft-capping：直接对打分做平滑限幅

给定正阈值 c，对尚未加掩码的 logits 应用

$$\mathrm{softcap}(z) = c\tanh(z/c).$$

小值附近近似线性，大值平滑趋近 $\pm c$。它会改变分布，并在饱和区减弱梯度；与不改变概率的“减去行最大值”不是同一件事。Gemma 2 的报告给出过注意力阈值 50、输出阈值 30，这些只是该配方的设置。

实现易错点：因果掩码应在 soft-cap 之后应用；若把 $-\infty$ 掩码先送入 tanh，会得到有限的 $-c$，从而破坏被屏蔽位置概率严格为零的约定。具体内核还需核对 mask、缩放与 soft-cap 的执行顺序。

6.6 三个技巧各管哪里？

方法	直接作用对象	不能据此保证什么
z-loss	输出层的 $\log Z$	不直接规范每层注意力 Q、K。
QK-norm	注意力的 Q、K	不自动解决输出 logits 漂移。
Soft-capping	注意力或输出 logits	有界分数不等于训练永不发散。

6.7 收束主线：一个可复用的实验顺序

先验证形状、因果掩码、标签错位、RoPE 位置和缓存一致性；再确认小规模能学习，观察训练 / 验证损失、梯度范数和 logits；最后在固定数据与预算下逐项比较结构。出现尖峰时同时检查数据、学习率、精度和状态恢复，不能默认全是架构问题。

本课学到的不是一张永远正确的配置表，而是一套判断方式：先解释机制，再核算资源，最后用质量、吞吐和稳定性共同验证。

7 一页速查：把本课压缩成一条链

7.1 六句话记住主线

1. **先搭主干：**注意力混合位置，FFN 变换特征，残差流始终回到 d 维。
2. **再稳信号：**Pre-norm 保留直通路径；RMSNorm 不减均值，二者是独立选择。
3. **然后编位置：**RoPE 旋转 Q、K，使内积中的位置作用体现为相对位移。
4. **再分预算：**普通 FFN 常取 $4d$，门控常取 $8d/3$；头总宽度等于 d 是惯例。
5. **最后看生成：**GQA / MQA 减少 KV 头，窗口减少位置连接，瓶颈需分别核算。
6. **训练要闭环：**优化设置与数值技巧一起检查，用质量、速度、稳定性验证改动。

7.2 关键公式与连续例子

检查项	公式或本例结论
Pre-norm	$y = x + F(N(x))$；区别于 $N(x + F(x))$。
RMSNorm	$\gamma_i x_i / \sqrt{\frac{1}{d}\sum_j x_j^2 + \epsilon}$。
FFN 预算	普通 $2dm$，门控 $3dm$；本例 $96 \to 64$，均 4608 个权重。
RoPE	$(R_i q)^\top (R_j k) = q^\top R_{j-i} k$。
注意力权重	$2d(h_q d_h) + 2d(h_{kv} d_h)$；别漏 Q 与输出投影。
小模型参数	$d = 24, L = 2, V = 64$：不共享词表权重时 17016。
KV 缓存	$2LBnh_{kv}d_h s$；本例 bf16：1536 / 512 / 256 byte。
稳定技巧	z-loss：$\alpha(\log Z)^2$；QK-norm：规范 Q、K；soft-cap：$c\tanh(z/c)$。

7.3 最容易混淆的地方

- **公式与惯例：**RMS 需要取平均；$h_q d_h = d$、$m/d = 8/3$ 不是普遍约束。
- **不同的账：**参数量、KV 容量、累计搬运量、FLOPs 和耗时不能互相替代。
- **相对位置与外推：**RoPE 的内积性质不保证任意长度效果，也不能重置缓存位置。
- **稳定实现与训练技巧：**减最大值不改变 softmax；soft-cap 改变分布，掩码应后加。

8 自测：能否脱离笔记说清楚？

先独立作答，再看下一节。计算题沿用 $d=24, L=2, V=64, B=2, n=4, h_q=6, d_h=4$；除特别说明外，线性层无偏置。

8.1 概念题

Q1. 分别解释 $N(x+F(x))$、$x+F(N(x))$ 和 $x+N(F(x))$。后两种为何都保留残差直通路径？采用 RMSNorm 是否就自动意味着 Pre-norm？

Q2. 普通 FFN 和 SwiGLU 分别怎样计算？SwiGLU 中额外增加的投影做什么？为什么不能把“门控”理解为让不同 token 彼此注意？

Q3. 用旋转矩阵说明 RoPE 为什么能让内积中的位置作用只依赖 $j-i$。该性质为何不能直接推出模型可以可靠处理任意长文本？

8.2 手算题

Q4. 普通 FFN 取 $m=96$，SwiGLU 应取多宽才能匹配权重数量？再计算普通 MHA 与 SwiGLU 的每层大矩阵参数。包含两层、两张独立词表矩阵及五个 RMSNorm 缩放向量后，总参数是多少？

Q5. bf16 KV cache 分别采用 $h_{kv}=6,2,1$ 时，全模型缓存各是多少 byte？若使用 GQA $(h_{kv}=2)$，每层注意力投影参数减少到多少？为什么缓存缩成 1/3，注意力参数却没有缩成 1/3？

Q6. 对输出 logits $z=(1000,1001)$，稳定地计算两个概率及 $\log Z$。若对两个 logits 都加上 7，交叉熵是否改变？z-loss 是否改变？

8.3 迁移题

Q7. 保持 $d=24, h_q=6$，把 d_h 改成 8 是否合法？普通 MHA 的 W_Q 与 W_O 形状如何变化？总投影参数变成多少？

Q8. 某模型训练吞吐不错，但 batch 为 1 的长文本生成很慢。至少指出两种可能的搬运瓶颈，以及各自的调整方向。如果把三层局部注意力与一层全局注意力交替，是否能把所有层的 KV cache 都截成窗口长度？

Q9. 有人把所有 logits 减最大值后，声称已经解决训练尖峰；又对加完因果掩码的分数做 soft-cap。分别指出这两个判断的问题，并说明 z-loss、QK-norm 主要作用于哪里。

掌握标准：能画出一个块的依赖关系，独立核算参数与缓存，并说清楚每个稳定技巧的作用对象和边界。

9 参考答案与资料来源

9.1 概念题参考答案

A1. 三式依次为传统 Post-norm、Pre-norm、分支输出归一化。后两式的 x 都直接加到输出；第一式的整条相加结果经过 N。RMSNorm 描述归一化函数，不决定它在块中的位置。

A2. 普通 FFN 是 $\phi(xW_1)W_2$；SwiGLU 是 $[\mathrm{SiLU}(xW_g)\odot xW_u]W_d$。额外投影形成逐特征调制，各位置分别计算，位置间的信息交换由注意力承担。

A3. $R(i\theta)^{\top}R(j\theta)=R((j-i)\theta)$，故固定内容时共同平移不改变内积。训练分布、频率设置、上下文与边界仍会影响长文本效果；公式可计算不等于已学会长距离任务。

9.2 手算题参考答案

A4. 令 $3\times 24\times m=2\times 24\times 96$，得 $m=64$。MHA 为 2304，SwiGLU 为 4608，每层大矩阵共 6912。总参数为

$$2\times 6912+2\times 64\times 24+5\times 24=17016.$$

A5. $M_{\mathrm{KV}}=2\times 2\times 2\times 4\times h_{kv}\times 4\times 2$，结果依次为 1536、512、256 byte。GQA 投影为 $2\times 24\times 24+2\times 24\times 8=1536$ 个参数；Q 和输出投影没有随 KV 头数一起缩小。

A6. 减去 1001 后，概率为 $(1/(1+e), e/(1+e))\approx(0.2689, 0.7311)$；$\log Z=1001+\log(1+e^{-1})\approx 1001.3133$。整体加 7 后，概率与交叉熵不变，$\log Z$ 增加 7，所以该例的 z-loss 改变。

9.3 迁移题参考答案

A7. 合法，注意力内部总宽度变成 48。W_Q 为 24×48，W_O 为 48×24；四类投影共 $4\times 24\times 48=4608$ 个权重，输出仍回到 24 维。

A8. 可能受权重搬运和历史 KV 读取限制：增大 batch 可摊薄权重搬运，GQA / MQA 减少 KV 读取；若质量允许，局部注意力减少历史范围。全局层仍需完整历史缓存，不能全部截断；需要实际测量确认主要瓶颈。

A9. 减最大值主要避免指数溢出，不消除所有优化或尺度问题。soft-cap 把掩码 $-\infty$ 变成有限 $-c$，应在限幅后再加掩码。z-loss 约束输出 $\log Z$；QK-norm 规范注意力 Q、K，二者不互相替代。

9.4 官方资料与阅读范围

- 课程官网及 Schedule：Spring 2026 第三课，Architectures, hyperparameters，授课教师 Tatsu Hashimoto；课程安排日期为 4 月 6 日。
- 第三课官方课件：本次读取主分支的 67 页 PDF，全文提取并查看各页图表。页码对应关系如下，方便回到原资料复习。

课件页码	主题	本笔记位置
1–9	现代 Transformer、模型对照与本课问题	第 1 节
10–19	归一化位置、RMSNorm、去偏置	第 2 节
20–29	激活、门控、串行与并行	第 2 节
30–35	位置编码与 RoPE	第 3 节
36–47、51	FFN、头维度、深宽比、词表	第 4 节
48–50、52–56	Dropout、衰减、数值稳定技巧	第 6 节
57–66	KV cache、GQA / MQA、稀疏与混合注意力	第 5 节
67	共性、差异与总结	第 7 节

9.5 直接相关原始资料：机制与实验

以下核对与本课有关的定义、公式、实验或图表，不把所有背景论文扩展成必读综述。链接均指向原始论文入口。

1. Vaswani 等：Attention Is All You Need。对应基础注意力、FFN、残差与位置编码。
2. Xiong 等：On Layer Normalization in the Transformer Architecture；Nguyen、Salazar：Transformers without Tears。对应 Pre / Post-norm 的梯度与训练实验。
3. Zhang、Sennrich：Root Mean Square Layer Normalization；Ivanov 等：Data Movement Is All You Need。对应均方根定义与 FLOPs / 时间差异。
4. Shazeer：GLU Variants Improve Transformer；Narang 等：Do Transformer Modifications Transfer Across Implementations and Applications?。对应门控公式、预算匹配及跨设置验证。
5. Su 等：RoFormer。对应第 3 节的位置编码推导与实现。

9.6 直接相关原始资料：配置、推理与稳定性

6. Kaplan 等：Scaling Laws for Neural Language Models；Tay 等：Scale Efficiently。对应模型形状、质量和效率的比较边界。
7. Raffel 等：Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer。核对 T5-11B 的特殊 FFN 与头维度配置。
8. Chowdhery 等：PaLM。核对并行分支、无偏置、头维度与输出 z-loss。
9. Shazeer：Fast Transformer Decoding；Ainslie 等：GQA。对应 KV 共享、增量解码、I/O 分析和质量取舍。
10. Child 等：Generating Long Sequences with Sparse Transformers。对应稀疏连接与多层信息可达性。
11. D'Angelo、Andriushchenko 等：Why Do We Need Weight Decay in Modern Deep Learning?。对应近单遍语言模型训练中的优化动态与低精度稳定性。
12. Gemma Team：Gemma 2；OLMo Team：2 OLMo 2 Furious。核对分支归一化、QK-norm、z-loss、soft-capping 与局部 / 全局层的相关设计。

9.7 版本差异、纠正与补充解释

本笔记依据本次读取的 Spring 2026 官网和主分支课件。主分支可能继续更新，课件中的模型列表混合了不同年份的样本；“常见”仅概括相关样本，不能理解为永恒标准。文件指纹与具体检查结果见同目录 README 和检查记录。

课件第 14 页的 RMSNorm 公式没有明确写出均方根的 $1/d$，笔记按原论文补全；第 43 页 PaLM 的头维度与比例存在不一致。按 PaLM 论文，540B 配置为 $48 \times 256/18432 = 2/3$，而非课件表中的 1.48。它仍支持“头总宽度不必等于模型宽度”，但方向与数值应重新核算。

课件第 28 页引文中的串行块表达式易漏掉注意力残差贡献，笔记统一采用先算 U、再算 Y 的完整两步式。MQA 的“一个维度”统一解释为一组 KV 头；算术强度推导明确区分整段、单步和累计口径。课件第 55 页的模型名单不作逐项事实表：例如 Gemma 2 报告的主要相关机制是 soft-capping 与子层双归一化，不能据名单推断它使用同样的 QK-norm。

小型连续例子、雅可比解释、参数与缓存手算、数值稳定例子、窗口感受野以及自测题为辅助推导，**不是课堂逐字记录或作业标准答案**。已覆盖课件全部教学主题，但未声称完整观看课堂录像、精读所有被展示的模型报告或独立验证每个模型的全部超参数。